

EchoMind 重点代码讲解(复制权限已开)

前言

有需要的可以下载pdf。但是请不要倒卖，这个项目我沉淀了很久，定价也不是很高，感谢🙏（最后有用的话记得多推荐一下😊）

求反馈（重要

大家觉得这个项目怎么样？用过这个项目的或者看完项目的可以在小红书找我给我反馈一下用着怎么样（球球了，想收集一波建议，也找一下优化方向）

pdf:

📖pdf材料下载 (密码: a3344521..)

本文档讲解 EchoMind 中最能体现工程设计的关键代码。内容按实际请求链路组织，而不是按文件顺序罗列。

重要说明：EchoMind 当前代码中已经实现端到端评测链路，核心文件为 `evaluation/evaluator.py`，HTTP 入口为 `api/main.py` 中的 `POST /eval/run`。评测不是简单 mock，而是真实调用 `AgentOrchestrator.run()` 生成回复，再用 LLM-as-Judge 从相关性、准确性、完整性、有用性四个维度评分，并支持意图识别 Accuracy/Macro-F1、回归检测和优化建议。

1. /chat 主链路

文件: `api/main.py`

/chat 是系统主入口，完整串起记忆、知识库检索、意图识别、Agent 路由、Skills 注入、回复生成和画像更新。

代码块

```

1 @app.post("/chat", response_model=ChatResponse)
2 async def chat(req: ChatRequest):
3     if _orchestrator is None or _memory is None:
4         raise HTTPException(503, "服务未就绪")
5
6     conv_id = req.conv_id or str(uuid.uuid4())
7
8     # 1. 读取记忆上下文

```

```

9      mem_ctx = await _memory.get_context(req.user_id, conv_id,
query=req.message)
10
11      # 2. 取最近对话，给意图识别使用
12      history = [
13          {"role": m.role.value, "content": m.content}
14          for m in mem_ctx.recent_messages[-5:]
15      ] if mem_ctx.recent_messages else None
16
17      # 3. 检索知识库，并和记忆上下文一起拼入 Agent 背景
18      knowledge_text, knowledge_used = await
_build_knowledge_context(req.message)
19      context_parts = [mem_ctx.to_prompt_text()]
20      if knowledge_text:
21          context_parts.append(knowledge_text)
22      full_context = "\n\n".join(part for part in context_parts if part)
23
24      # 4. 构造 Orchestrator 请求
25      orch_req = OrcReq(
26          message=req.message,
27          user_id=req.user_id,
28          conv_id=conv_id,
29          context=full_context,
30          history=history,
31      )
32
33      # 5. 执行 Agent 编排
34      result = await _orchestrator.run(orch_req)
35
36      # 6. 写入工作记忆
37      await _memory.add_message(req.user_id, conv_id, MsgRole.USER, req.message)
38      await _memory.add_message(req.user_id, conv_id, MsgRole.ASSISTANT,
result.response)
39
40      # 7. 异步更新用户画像，不阻塞响应
41      asyncio.create_task(_memory.update_profile(req.user_id, conv_id))

```

关键点

步骤	作用
get_context()	一次性读取工作记忆、情景记忆、用户画像和摘要
history	

	只取最近 5 条，控制意图识别 prompt 长度
_build_knowledge_context()	调用知识库检索、查询改写、并行召回和重排
context=full_context	把三级记忆和 Top-K 知识库结果拼成 Agent 可读背景信息
Agent._build_system_prompt()	在 LLM 调用前按 Agent 类型和用户消息注入匹配 Skills
add_message()	用户消息和助手回复都写入 Redis 工作记忆
update_profile()	后台异步提炼用户偏好，不影响接口延迟

2. 意图识别：三路融合 + 加权投票

文件：[core/intent_recognizer.py](#)

主识别流程

代码块

```
1  async def recognize(self, message: str, history=None) -> IntentResult:
2      key = self._cache_key(message)
3      if key in self._cache:
4          self.cache_hits += 1
5          return self._cache[key]
6      self.cache_misses += 1
7
8      t0 = time.monotonic()
9
10     llm_task = asyncio.create_task(self._llm_recognize(message, history))
11     emb_task = asyncio.create_task(self._embedding_recognize(message)) if
self._embedding_enabled else None
12     pat = self._pattern_recognize(message)
13
14     if emb_task:
15         llm, emb = await asyncio.gather(llm_task, emb_task)
16     else:
17         llm = await llm_task
```

```
18         emb = {"intent": IntentCategory.OTHER, "confidence": 0.0}
19
20     intent = self._vote(llm, emb, pat)
21     entities = await self._extract_entities(message)
22     urgency = self._urgency(message, intent)
```

为什么这样写

代码	设计意义
asyncio.create_task()	LLM 和 Embedding 同时开始，避免串行等待
pat = self._pattern_recognize()	关键词匹配是本地 CPU 操作，零网络延迟
asyncio.gather()	总耗时接近最慢的那一路，而不是两路相加
_vote()	三路结果统一成一个最终意图
_extract_entities()	意图之外额外提取订单号、金额、错误码等实体

加权投票

代码块

```
1  def _vote(self, llm: Dict, emb: Dict, pat: Dict) -> IntentCategory:
2      if self._embedding_enabled:
3          weights = [(llm, 0.7), (emb, 0.2), (pat, 0.1)]
4      else:
5          weights = [(llm, 0.85), (pat, 0.15)]
6
7      scores: Dict[IntentCategory, float] = {}
8      for result, w in weights:
9          cat = result.get("intent", IntentCategory.OTHER)
10         conf = result.get("confidence", 0.0)
11         scores[cat] = scores.get(cat, 0.0) + w * conf
12
13     best = max(scores, key=scores.get)
14     return best if scores[best] >= self.threshold else IntentCategory.OTHER
```

权重策略：

模式	权重
官方 API 模式	LLM 70% + Embedding 20% + Pattern 10%
第三方兼容 API 模式	LLM 85% + Pattern 15%，禁用 Embedding

Embedding 兜底

当前 Anthropic SDK 没有 embeddings 资源，所以代码做了远端优先、本地兜底：

代码块

```
1  async def _embed_text(self, text: str) -> List[float]:
2      embeddings = getattr(self.client, "embeddings", None)
3      if embeddings is not None:
4          try:
5              resp = await embeddings.create(model="voyage-3-lite", input=[text])
6              return list(resp.data[0].embedding)
7          except Exception as ex:
8              logger.warning(f"远端 Embedding 失败，使用本地向量兜底：{ex}")
9
10     return self._local_embedding(text)
```

本地向量是稳定的字符 n-gram 哈希向量：

代码块

```
1  @staticmethod
2  def _local_embedding(text: str, dims: int = 256) -> List[float]:
3      normalized = text.lower().strip()
4      vec = [0.0] * dims
5      tokens = set()
6      for n in (1, 2, 3):
7          if len(normalized) >= n:
8              tokens.update(normalized[i:i + n] for i in range(len(normalized) -
9                  n + 1))
10
11     for token in tokens:
12         digest = hashlib.md5(token.encode("utf-8")).digest()
13         idx = int.from_bytes(digest[:4], "big") % dims
14         sign = 1.0 if digest[4] % 2 == 0 else -1.0
15         vec[idx] += sign
16     return vec
```

这个设计保证了“Embedding 路”不会因为 SDK 缺能力而完全不可用。

3. MCP 工具调用：缓存、熔断、fallback

文件：mcp/[tool_manager.py](#)

工具调用生命周期

代码块

```
1  async def call(self, name, params, context=None, *, use_cache=True,
    rerank_top_k=0):
2      tool = self._tools.get(name)
3      if not tool:
4          return ToolResult(success=False, data=None, tool_name=name, error=f"工具
    不存在: {name}")
5
6      if use_cache and tool.cache_ttl > 0:
7          cached = self._get_cache(name, params)
8          if cached is not None:
9              tool.stats.total += 1
10             tool.stats.success += 1
11             return ToolResult(success=True, data=cached, tool_name=name,
    cached=True)
12
13     if not tool.breaker.allow():
14         error = f"工具熔断中: {name}, 请稍后重试"
15         return await self._fallback_result(tool, params, context, error)
16
17     tool.stats.total += 1
18     try:
19         self._validate_params(tool, params)
20         data = await asyncio.wait_for(tool.handler(params, context),
    timeout=tool.timeout_s)
21         ...
22     except asyncio.TimeoutError:
23         ...
24         return await self._fallback_result(tool, params, context, "执行超时")
25     except Exception as ex:
26         ...
27         return await self._fallback_result(tool, params, context, str(ex))
```

重点设计

环节	目的
缓存检查	相同参数直接返回，降低检索和 LLM 重排成本
熔断检查	工具连续失败后短期拒绝请求，避免雪崩
参数校验	使用 JSON Schema 检查 required 和类型
asyncio.wait_for	工具级超时，避免请求无限挂起
统计更新	记录成功率、延迟、连续失败，供 Monitor 使用
fallback	工具失败时返回可解释降级结果

fallback 实现

代码块

```
1  async def _fallback_result(self, tool, params, context, error) -> ToolResult:
2      if tool.fallback is None:
3          return ToolResult(success=False, data=None, tool_name=tool.name,
4              error=error)
5      try:
6          data = tool.fallback(params, context, error)
7          if asyncio.iscoroutine(data):
8              data = await data
9          return ToolResult(
10              success=True,
11              data=data,
12              tool_name=tool.name,
13              error=error,
14          )
15      except Exception as ex:
16          return ToolResult(
17              success=False,
18              data=None,
19              tool_name=tool.name,
20              error=f"{error}; fallback失败: {ex}",
21          )
```

在 `api/main.py` 中，知识库工具注册了 `fallback`:

代码块

```
1 def knowledge_fallback(params, context, error):
2     query = params.get("query", "")
3     return [{
4         "title": "知识库降级结果",
5         "content": f"知识库暂时不可用，未能完成对“{query}”的语义检索。请稍后重试，或转人工客服确认。",
6         "score": 0.0,
7         "fallback": True,
8         "error": error,
9     }]
```

4. 查询改写 + 并行召回 + LLM 重排

文件: `mcp/tool_manager.py`

代码块

```
1 async def search_with_rewrite(self, tool_name, query, top_k=5, context=None) -
  > ToolResult:
2     sub_queries = await self.rewrite_query(query, n=3)
3
4     recall_k = max(top_k, 5)
5     tasks = [
6         self.call(tool_name, {"query": q, "top_k": recall_k}, context,
7         use_cache=True)
8         for q in sub_queries
9     ]
10
11     results = await asyncio.gather(*tasks, return_exceptions=True)
12
13     seen, merged = set(), []
14     for r in results:
15         if isinstance(r, ToolResult) and r.success and isinstance(r.data,
16         list):
17             for item in r.data:
18                 key = hashlib.md5(str(item).encode()).hexdigest()
19                 if key not in seen:
20                     seen.add(key)
21                     merged.append(item)
22
23     if not merged:
```



```
21         return ToolResult(success=False, data=[], tool_name=tool_name,
22                             error="所有子查询均无结果")
23
24     reranked = await self._rerank(query, merged, top_k)
25     return ToolResult(success=True, data=reranked, tool_name=tool_name,
26                       reranked=True)
```

这里有一个容易忽略的细节：每个子查询召回 $\text{recall_k} = \max(\text{top_k}, 5)$ 条，而不是只召回 top_k 条。这样重排阶段有更大的候选池，避免过早截断。

解决的问题

问题	代码策略
单 query 召回不全	rewrite_query() 生成多个角度
多 query 增加延迟	asyncio.gather() 并行召回
重复片段过多	内容 MD5 去重
向量排序不等于答案质量	_rerank() 使用 LLM 重排

5. ChromaDB 知识库

文件：mcp/[knowledge_base.py](#)

初始化

代码块

```
1  try:
2      self._client = chromadb.HttpClient(host=chroma_host, port=chroma_port)
3      self._client.heartbeat()
4      self._use_server = True
5  except Exception:
6      self._client = chromadb.PersistentClient(
7          path=chroma_path,
8          settings=chromadb.Settings(anonymized_telemetry=False),
9      )
10
11  self._collection = self._client.get_or_create_collection(
12      name=self.COLLECTION_NAME,
```

```
13     metadata={"description": "EchoMind RAG 知识库"},
14 )
15
16 if self._collection.count() == 0:
17     self._load_default_docs()
```

关键点

设计	作用
优先 HttpClient	Docker Compose 下连接独立 ChromaDB 服务
失败降级 PersistentClient	本地开发时没有 ChromaDB 服务也能运行
collection 名称 knowledge_base	和记忆模块的 episodic、user_profile 隔离
空库自动导入默认文档	项目启动后可以直接演示检索

检索

代码块

```
1 results = self._collection.query(
2     query_texts=[query],
3     n_results=top_k,
4 )
```

ChromaDB 会对 query_texts 自动生成向量并做语义匹配。返回结果会被转换成：

代码块

```
1 {
2     "title": meta.get("title", ""),
3     "content": doc,
4     "score": round(1.0 - dist, 4),
5     "chunk": meta.get("chunk_index", 0),
6 }
```

6. 三级记忆：Redis + ChromaDB

文件：memory/[conversation_memory.py](#)

写入工作记忆

代码块

```
1  async def add_message(self, user_id, conv_id, role, content, metadata=None):
2      key = self._wm_key(user_id, conv_id)
3
4      self._redis.lpush(key, json.dumps({
5          "role": msg.role.value,
6          "content": msg.content,
7          "ts": msg.timestamp.isoformat(),
8          "metadata": msg.metadata,
9      }))
10     self._redis.expire(key, 86400)
11
12     if self._redis.llen(key) >= self.COMPRESS_AT:
13         await self._compress(user_id, conv_id)
```

Redis key:

代码块

```
1  wm:{user_id}:{conv_id}
```

自动压缩

代码块

```
1  async def _compress(self, user_id, conv_id):
2      messages = await self._get_working_memory(user_id, conv_id)
3      if len(messages) < self.COMPRESS_AT:
4          return
5
6      to_compress = messages[::-5]
7      keep = messages[-5:]
8
9      text = "\n".join(f"{m.role.value}: {m.content}" for m in to_compress)
10     prompt = f"用 2-3 句话总结以下对话的关键信息：\n{text}"
11     ...
12     self._redis.setex(skey, 86400, new_summary)
```

```
13         await self._store_episodic(user_id, conv_id, text, summary)
```

压缩后的摘要会写入 ChromaDB collection:

代码块

```
1     episodic
```

用户画像

代码块

```
1     async def update_profile(self, user_id: str, conv_id: str) -> None:
2         messages = await self._get_working_memory(user_id, conv_id)
3         text = "\n".join(f"{m.role.value}: {m.content}" for m in messages[-10:])
4
5         prompt = f"""从以下对话中提炼用户偏好和关键实体，返回 JSON。
6 对话:
7 {text}
8
9 返回格式: {{{"preferences": ["..."], "entities": {{{"产品": [], "问题类型":
    []}}}}"""
```

画像写入 ChromaDB collection:

代码块

```
1     user_profile
```

下一次请求时，get_context() 会读取画像并拼入 prompt:

代码块

```
1     if self.user_profile:
2         parts.append(f"[用户画像]\n{json.dumps(self.user_profile,
    ensure_ascii=True)}")
```

三个存储层

层级	存储	内容

工作记忆	Redis	当前会话最近消息，24h TTL
情景记忆	ChromaDB episodic	压缩后的历史对话摘要
用户画像	ChromaDB user_profile	用户偏好和关键实体

7. Agent 路由：意图映射、性能路由、降级

文件：agents/agent_orchestrator.py

主流程

代码块

```
1  async def run(self, req: Request) -> OrchestratorResult:
2      if req.intent is None:
3          intent_result = await self._intent_recognizer.recognize(req.message,
4              history=req.history)
5          req.intent = intent_result.intent
6          req.urgency = intent_result.urgency
7
8      collaboration = self._collaboration_targets(req)
9      if len(collaboration) > 1:
10         return await self.run_parallel(req, collaboration)
11
12     agent_type = self._route(req.intent, req.urgency)
13     response = await self._execute(req, agent_type)
```

当前实现里，复合问题检测已经接入主链路。不是只有手动调用 run_parallel() 才会并行协作。

意图路由

代码块

```
1  _INTENT_ROUTING = {
2      IntentCategory.TECHNICAL:  AgentType.TECHNICAL,
3      IntentCategory.BILLING:    AgentType.BILLING,
4      IntentCategory.ACCOUNT:    AgentType.BILLING,
5      IntentCategory.ESCALATION: AgentType.ESCALATION,
6  }
```

复合问题检测

```

1 代码块 def _collaboration_targets(self, req: Request) -> List[AgentType]:
2      msg = req.message.lower()
3      targets: List[AgentType] = []
4
5      technical_kws = ["崩溃", "报错", "error", "crash", "无法登录", "登录失败",
6      "500", "401"]
7      billing_kws = ["退款", "扣款", "发票", "账单", "支付", "订阅", "refund",
8      "invoice"]
9
10     if req.intent == IntentCategory.TECHNICAL or any(kw in msg for kw in
11     technical_kws):
12         targets.append(AgentType.TECHNICAL)
13     if req.intent in (IntentCategory.BILLING, IntentCategory.ACCOUNT) or
14     any(kw in msg for kw in billing_kws):
15         targets.append(AgentType.BILLING)
16
17     deduped = list(dict.fromkeys(targets))
18     return [agent_type for agent_type in deduped if self._pool.get(agent_type)]

```

示例：

代码块

```

1 登录报错 401，而且这个月还重复扣款了

```

会触发：

代码块

```

1 TechnicalAgent + BillingAgent

```

Skills 与 Agent 执行

每个 Agent 执行 LLM 调用前都会构建 system prompt：

代码块

```

1 def _build_system_prompt(self, req: Request) -> str:
2     if self._skill_manager is None:
3         return self.system_prompt
4     skill_prompt = self._skill_manager.prompt_for(req.message,
5     self.agent_type.value)
6     if not skill_prompt:
7         return self.system_prompt

```

```
7         return f"{self.system_prompt}\n\n[动态 Skills]\n{skill_prompt}"
```

这意味着 Skills 不影响意图识别和路由结果，而是在“选定 Agent 后、调用 LLM 前”生效。这样可以保证：

- GeneralAgent 只注入通用客服接待规范。
- TechnicalAgent 只注入技术支持处理规范。
- BillingAgent 只注入账单退款处理规范。
- 复合问题并行时，技术和账单两个 Agent 会分别注入各自的 Skills。

以 GeneralAgent 为例，它继承 BaseAgent，并声明：

代码块

```
1 class GeneralAgent(BaseAgent):  
2     agent_type = AgentType.GENERAL
```

所以执行 `_build_system_prompt()` 时传给 SkillManager 的第二个参数是：

代码块

```
1 self.agent_type.value # "general"
```

对应调用链是：

代码块

```
1 GeneralAgent.handle(req)  
2     -> BaseAgent._call_llm(req)  
3     -> BaseAgent._build_system_prompt(req)  
4     -> SkillManager.prompt_for(req.message, "general")  
5     -> Skill.matches(message, "general")
```

skills/general_customer_service/[SKILL.md](#) 顶部配置了：

代码块

```
1 agents: general  
2 keywords: 你好,您好,咨询,帮助,客服,订单,售后,活动,会员,账户,资料,投诉,建议,人工,转人工,  
   处理进度,服务  
3 enabled: true
```

因此当用户消息命中这些关键词时，该 Skill 会被注入；如果当前 Agent 是 technical 或 billing，则会因为 agents 不匹配而跳过。

性能路由

代码块

```
1 def _best_agent(self, agent_type: AgentType) -> Optional[BaseAgent]:
2     agents = self._pool.get(agent_type, [])
3     if not agents:
4         return None
5     return max(agents, key=lambda a: a.stats.routing_score())
```

8. 动态 Skills 加载与热更新

文件：core/[skill_loader.py](#)、api/[main.py](#)、agents/[agent_orchestrator.py](#)

Skill 数据结构

代码块

```
1 @dataclass
2 class Skill:
3     name: str
4     description: str
5     content: str
6     path: str
7     keywords: List[str] = field(default_factory=list)
8     agents: List[str] = field(default_factory=list)
9     enabled: bool = True
```

Skill 会把 Markdown 或 JSON 文件统一成运行时对象。keywords 控制触发条件，agents 控制适用 Agent，enabled 控制是否启用。

匹配逻辑

代码块

```
1 def matches(self, message: str, agent_type: Optional[str] = None) -> bool:
2     if not self.enabled:
3         return False
4     if self.agents and agent_type and agent_type.lower() not in self.agents:
5         return False
```



```
6     if not self.keywords:
7         return True
8     lowered = (message or "").lower()
9     return any(keyword.lower() in lowered for keyword in self.keywords)
```

关键点：

条件	行为
enabled=false	不注入
agents 不包含当前 Agent	不注入
keywords 为空	作为该 Agent 的全局规则
keywords 命中用户消息	注入到 system prompt

prompt_for 的完整筛选过程

SkillManager.prompt_for() 会遍历已加载的所有 Skill，并调用 matches() 判断是否适用于当前请求：

代码块

```
1  for skill in self._skills:
2      if not skill.matches(message, agent_type):
3          continue
4      block = skill.to_prompt_block()
5      ...
6      blocks.append(block)
```

筛选顺序可以理解为：

代码块

1. Skill 是否启用
2. Skill 的 agents 是否包含当前 Agent 类型
3. Skill 的 keywords 是否命中用户消息
4. 命中后格式化为 prompt block
5. 拼接成 [动态 Skills] 区块返回给 Agent

如果没有任何 Skill 匹配，prompt_for() 返回空字符串，Agent 会只使用原始 system_prompt。

目录扫描

```

1 代码块 def _discover_files(self, root_dir: Path) -> Iterable[Path]:
2      skill_md_files = sorted(root_dir.rglob("SKILL.md"))
3      ...
4      for path in sorted(root_dir.rglob("*")):
5          if path.suffix.lower() in self.SUPPORTED_SUFFIXES:
6              yield path

```

支持两种结构：

代码块

```

1  skills/technical_support/SKILL.md
2  skills/billing_support.json

```

API 初始化

api/[main.py](#) 在 lifespan 中加载 Skills：

代码块

```

1  skills_dir = os.getenv("ECHOMIND_SKILLS_DIR", str(pathlib.Path(_ROOT) /
2  "skills"))
3  _skill_manager = SkillManager(
4      root_dir=skills_dir,
5      max_prompt_chars=int(os.getenv("ECHOMIND_SKILLS_MAX_PROMPT_CHARS",
6      "5000")),
7  )
8  _skill_manager.load()
9
10 _orchestrator = AgentOrchestrator(..., skill_manager=_skill_manager)

```

CLI 模式也使用同一套加载逻辑，避免 HTTP 和 CLI 行为不一致。

热加载接口

代码块

```

1  @app.post("/skills/reload", tags=["Skills"])
2  async def reload_skills():
3      _skill_manager.reload()
4      if _orchestrator is not None:
5          _orchestrator.set_skill_manager(_skill_manager)
6      return _skill_manager.summary()

```

修改 skills/*/SKILL.md 后调用 /skills/reload 即可生效，不需要重启服务。

9. routing_score 与 Monitor 降权

文件：agents/agent_orchestrator.py、monitor/performance_monitor.py

AgentStats

代码块

```
1  @dataclass
2  class AgentStats:
3      total: int = 0
4      success: int = 0
5      total_ms: float = 0.0
6      monitor_penalty: float = 0.0
7
8      def routing_score(self) -> float:
9          latency_score = 1.0 / (1.0 + self.avg_ms / 1000)
10         base_score = self.success_rate * 0.7 + latency_score * 0.3
11         return base_score * max(0.0, 1.0 - self.monitor_penalty)
```

Monitor 采集并写回 penalty

代码块

```
1  async def _collect(self) -> None:
2      agent_stats = self._orchestrator.get_stats()
3      tool_stats = self._tool_manager.get_stats()
4      routing_penalties: Dict[str, float] = {}
5
6      for agent_key, s in agent_stats.items():
7          sr = s["success_rate"]
8          ms = s["avg_ms"]
9          ...
10         routing_penalties[agent_key] = self._routing_penalty(sr, ms)
11
12     updater = getattr(self._orchestrator, "update_routing_penalties", None)
13     if updater:
14         updater(routing_penalties)
```

降权规则

```

1 @staticmethod
2 def _routing_penalty(success_rate: float, avg_ms: float) -> float:
3     penalty = 0.0
4     if success_rate < 0.90:
5         penalty += min(0.5, (0.90 - success_rate) * 2)
6     if avg_ms > 3000:
7         penalty += min(0.4, (avg_ms - 3000) / 10000)
8     return min(penalty, 0.9)

```

写回 Orchestrator

代码块

```

1 def update_routing_penalties(self, penalties: Dict[str, float]) -> None:
2     for agent_type, agents in self._pool.items():
3         for i, agent in enumerate(agents):
4             key = f"{agent_type.value}_{i}"
5             penalty = penalties.get(key, 0.0)
6             agent.stats.monitor_penalty = min(max(penalty, 0.0), 0.9)

```

这是真正的 Monitor 闭环：Monitor 不只是展示指标，而是会影响下一次 `_best_agent()` 的路由选择。

10. LLM-as-Judge 端到端评测

文件：evaluation/[evaluator.py](#)

真实调用 Orchestrator

代码块

```

1 orch_req = OrcReq(
2     message=question,
3     user_id=user_id,
4     conv_id=conv_id,
5     context=context,
6     history=history[-6:] if history else None,
7 )
8 orch_result = await self._orchestrator.run(orch_req)
9 actual_answer = orch_result.response

```

评测不是 mock 回复，而是真正走 Agent 编排链路。多轮用例会复用同一个 conv_id，并把前序轮次拼成评测历史上下文。

四维度评分

代码块

```
1  return QualityScores(  
2      relevance=float(data.get("relevance", 0.5)),  
3      accuracy=float(data.get("accuracy", 0.5)),  
4      completeness=float(data.get("completeness", 0.5)),  
5      helpfulness=float(data.get("helpfulness", 0.5)),  
6  )
```

维度	含义
relevance	是否直接回应用户问题
accuracy	信息是否准确
completeness	是否完整解决需求
helpfulness	用户能否据此行动

回归检测

代码块

```
1  def _detect_regressions(self, current: Dict[str, float]) -> List[str]:  
2      prev_report = self._history[-1] if self._history else self._baseline  
3      if prev_report is None:  
4          return []  
5      prev = prev_report.avg_scores  
6      regressions = []  
7      for metric, value in current.items():  
8          if metric in prev and prev[metric] > 0:  
9              delta = (value - prev[metric]) / prev[metric]  
10             if delta < -0.05:  
11                 regressions.append(  
12                     f"{metric}: {prev[metric]:.3f} → {value:.3f} (退化  
13                     {abs(delta):.1%})"  
14                 )  
15             return regressions
```

当前评测支持内存中的上一轮结果，也支持通过 EVAL_BASELINE_PATH 持久化基线。Docker Compose 默认把基线保存到 /app/data/eval/baseline.json，宿主机可在 ./data/eval/baseline.json 查看。

11. Unicode 安全处理

文件: [agents/agent_orchestrator.py](#)

代码块

```
1  async def _call_llm(self, req: Request) -> str:
2      def _clean(s: str) -> str:
3          return s.encode("utf-8", errors="ignore").decode("utf-8")
4
5      messages = []
6      if req.context:
7          messages.append({"role": "user", "content": f"[背景信
            息]\n{_clean(req.context)}"})
8          messages.append({"role": "assistant", "content": "好的，我已了解背景信
            息。"})
9      messages.append({"role": "user", "content": _clean(req.message)})
```

ChromaDB 或 Redis 中可能存储包含 Unicode 代理字符的数据。_clean() 会在调用 LLM 前移除无法 UTF-8 编码的字符，避免 API 请求崩溃。

12. 环境自适应：官方 API 与第三方兼容 API

文件: [core/intent_recognizer.py](#)、[api/main.py](#)

配置读取：

代码块

```
1  def _anthropic_cfg() -> Dict[str, Any]:
2      key = os.getenv("ANTHROPIC_API_KEY", "")
3      if not key:
4          raise RuntimeError("未设置 ANTHROPIC_API_KEY")
5      cfg = {
6          "api_key": key,
7          "model": os.getenv("ANTHROPIC_MODEL", "claude-3-5-sonnet-20241022"),
8      }
9      base_url = os.getenv("ANTHROPIC_BASE_URL", "").strip()
10     if base_url:
11         cfg["base_url"] = base_url
```

```
12         return cfg
```

意图识别中根据 base_url 自动切换策略：

代码块

```
1     self._embedding_enabled = not bool(base_url)
```

模式	条件	行为
官方 Anthropic	ANTHROPIC_BASE_URL 为空	三路融合：LLM + Embedding + Pattern
第三方兼容 API	ANTHROPIC_BASE_URL 有值	两路融合：LLM + Pattern

调用层不需要关心差异，只需要通过环境变量切换。